



ÉCOLE NATIONALE SUPÉRIEURE
D'INFORMATIQUE ET D'ANALYSE DES SYSTÈMES
RABAT

RAPPORT DE PROJET — DATA-DRIVEN DECISION MAKING
(DDDM)

Système d'Aide à la Décision pour la
Fidélisation Client et l'Augmentation du
Chiffre d'Affaires dans le E-commerce

Réalisé par :

Aya MLOUKI / Wissal KALLAH

Encadré par :

Prof Youness TABII

Année universitaire : 2025–2026

Table des matières

Introduction Générale	4
1 Phase 1 : Business Understanding	5
1.1 Contexte et Domaine Métier	5
1.2 Datasets Utilisés	5
1.3 Problématique Métier et Question Décisionnelle	5
1.4 KPI Principal	6
1.5 KPIs Secondaires	6
1.6 KPI Tree	7
1.7 Business Case et ROI Estimé	8
2 Phase 2 : Collecte & Audit des Données	9
2.1 Cartographie des Sources de Données	9
2.2 Data Dictionary	9
2.3 Data Audit — Rapport Qualité	10
3 Phase 3 : ETL (Extract, Transform, Load)	12
3.1 Vue d'Ensemble du Pipeline ETL	12
3.2 Transform — Nettoyage des Données	12
3.3 Transform — Pipeline de Jointures	12
3.4 Transform — Feature Engineering	13
3.5 Load — Dataset Analytique Final	13
4 Phase 4 : Exploratory Data Analysis (EDA)	15
4.1 Analyse des Ventes	15
4.2 Analyse des Clients	15
4.3 Analyse des Produits	16
4.4 Analyse de la Satisfaction Client	16
4.5 Analyse de la Livraison	16
4.6 Analyse des Corrélations	17
4.7 Détection des Outliers	17
5 Phase 5 : Tests Statistiques	18
5.1 Objectif et Méthodologie	18
5.2 Test 1 — Retard de Livraison vs Satisfaction Client	18
5.3 Test 2 — Catégorie Produit vs Satisfaction	18
5.4 Test 3 — Fidélité Client vs Dépense Totale	19

5.5	Test 4 — Fidélité Client vs Note Moyenne	19
5.6	Test 5 — État Brésilien vs Taux de Retard	19
5.7	Test 6 — Fidélité Client vs Récence	20
5.8	Récapitulatif des Tests	20
6	Phase 6 : Clustering K-Means (Segmentation RFM)	21
6.1	Objectif et Méthodologie	21
6.2	Choix du Nombre de Clusters	21
6.3	Résultats : Quatre Segments Identifiés	22
7	Phase 7 : Feature Engineering ML	23
7.1	Objectif	23
7.2	Variable Cible	23
7.3	Features Retenues (6 variables)	23
7.4	Importance des Features	24
7.5	Preprocessing	24
8	Phase 8 : Modélisation Prédictive	25
8.1	Question Prédictive	25
8.2	Préparation des Données	25
8.3	Résultats des Trois Modèles	25
9	Phase 9 : Validation & Comparaison des Modèles	27
9.1	Objectif	27
9.2	Résultats de la Cross-Validation 5-Fold	27
9.3	Optimisation GridSearchCV	28
9.4	Résultats Finaux — Modèles Optimisés	28
9.5	Modèle Retenu	29
10	Phase 10 : Interprétabilité SHAP	30
10.1	Principe et Explainer Utilisé	30
10.2	Analyse Globale : Importance et Direction des Variables	30
10.3	Insights Métier SHAP	32
11	Phase 11 : Dashboard Power BI	33
11.1	Présentation Générale	33
11.2	Page 1 — Vue d'Ensemble des KPIs	33
11.3	Page 2 — Analyse Clients	34
11.4	Page 3 — Analyse Produits	35

11.5	Page 4 — Satisfaction & Livraison	36
11.6	Page 5 — Habitudes d'Achat Instacart	37
12	Phase 12 : Recommandations Décisionnelles	38
12.1	Méthodologie et Synthèse du Pipeline	38
12.2	Recommandation 1 — Programme de Fidélisation Premium	38
12.2.1	Constat	38
12.2.2	Action Proposée	38
12.2.3	Gain Estimé et KPIs de Suivi	39
12.3	Recommandation 2 : Campagne de Réactivation des Clients à Risque . . .	39
12.3.1	Constat	39
12.3.2	Action Proposée	39
12.3.3	Gain Estimé et KPIs de Suivi	40
12.4	Recommandation 3 — Déploiement du Score de Propension ML en Pro- duction	40
12.4.1	Constat	40
12.4.2	Action Proposée	40
12.4.3	Gain Estimé et KPIs de Suivi	41
12.5	Récapitulatif des Recommandations	42
13	Phase 13 : Plan A/B Testing	43
13.1	Objectif et Principe	43
13.2	Test A/B n°1 — Validation de la Campagne de Réactivation (R2)	43
13.2.1	Hypothèse	43
13.2.2	Protocole Expérimental	43
13.2.3	Calcul de la Taille d'Échantillon	44
13.2.4	Règle de Décision	44
13.2.5	Risques et Mesures d'Atténuation	45
13.3	Test A/B n°2 — Validation du Score de Propension ML (R3)	45
13.3.1	Hypothèse	45
13.3.2	Protocole Expérimental	45
13.3.3	Calcul de la Taille d'Échantillon	46
13.3.4	Règle de Décision	46
13.3.5	Risques et Mesures d'Atténuation	46
13.4	Plan d'Analyse Statistique Post-Test	47
13.5	Récapitulatif des Deux Tests	48
	Conclusion Générale	49

Introduction Générale

Dans un environnement e-commerce de plus en plus concurrentiel, la capacité à transformer les données en décisions constitue un avantage stratégique déterminant. Ce projet s'inscrit dans le cadre du module Data-Driven Decision Making et vise à construire, de bout en bout, un système d'aide à la décision dédié à l'amélioration de la fidélisation client et à l'augmentation du chiffre d'affaires d'une plateforme de commerce électronique. En s'appuyant sur trois datasets réels totalisant plusieurs millions d'enregistrements, le projet couvre l'intégralité du pipeline décisionnel basé sur la donnée, depuis le cadrage métier jusqu'aux recommandations actionnables et au plan de mesure d'impact.

1 Phase 1 : Business Understanding

1.1 Contexte et Domaine Métier

Le domaine retenu pour ce projet est le **commerce électronique (e-commerce)**. Ce secteur présente la particularité de générer quotidiennement un volume considérable de données structurées : commandes, paiements, avis clients, délais de livraison, compositions de paniers. Ces données constituent un actif stratégique majeur pour les entreprises qui savent les exploiter.

Un constat fondamental motive ce projet : dans un marché e-commerce fortement concurrentiel, **acquérir un nouveau client coûte en moyenne cinq à sept fois plus cher que de conserver un client existant** (Harvard Business Review). Par conséquent, la fidélisation client représente un levier de croissance du chiffre d'affaires plus efficace et moins coûteux que l'acquisition pure.

1.2 Datasets Utilisés

Le projet s'appuie sur trois datasets complémentaires, tous issus de la plateforme Kaggle :

Dataset	Source	Volume	Utilisation
Olist Brazilian E-Commerce	Kaggle	~100 000 commandes	Ventes, clients, paiements, livraisons, avis
Instacart Market Basket Analysis	Kaggle	~3,4M commandes, 206K clients	Habitudes d'achat, composition de panier, fréquence
Amazon Product Reviews	Kaggle	4 915 avis, 12 colonnes	Satisfaction client, analyse des notes

TABLE 1 – Récapitulatif des datasets utilisés

1.3 Problématique Métier et Question Décisionnelle

La question décisionnelle principale du projet est :

« Comment une plateforme e-commerce peut-elle exploiter les données de ventes, de comportement d'achat et de satisfaction client afin d'améliorer la fidélisation des clients et d'augmenter son chiffre d'affaires ? »

Cette question centrale se décline en cinq sous-questions opérationnelles :

1. Quels clients présentent un risque élevé de désengagement ?
2. Quels facteurs influencent le plus la satisfaction client ?
3. Quels produits génèrent le plus de revenus ?
4. Quel impact les retards de livraison ont-ils sur la satisfaction des clients ?
5. Quels segments de clients doivent être ciblés en priorité ?

1.4 KPI Principal

Le KPI principal retenu est le **Customer Retention Rate (Taux de Fidélisation)**, qui mesure la capacité de la plateforme à conserver ses clients actifs dans le temps :

$$\text{Taux de Fidélisation} = \frac{\text{Nombre de clients ayant effectué un nouvel achat}}{\text{Nombre total de clients}} \times 100 \quad (1)$$

Ce KPI est central pour trois raisons :

- Les clients fidèles achètent plus fréquemment et génèrent davantage de revenus à long terme.
- Leur Lifetime Value (LTV) est significativement plus élevée que celle des clients one-shot.
- Le coût de rétention est inférieur au coût d'acquisition de nouveaux clients.

1.5 KPIs Secondaires

Catégorie	KPI	Description
4*Performance Commerciale	Chiffre d'affaires total	Somme de tous les paiements
	Croissance des ventes	$(\text{CA mois } N - \text{CA mois } N-1) / \text{CA mois } N-1$
	Nombre total de commandes	$\text{Count}(\text{order_id})$
	Panier moyen	$\text{CA total} / \text{Nombre de commandes}$
3*Activité Client	Clients actifs	Commandé dans les 90 derniers jours
	Taux de réachat	$\text{Clients } \geq 2 \text{ commandes} / \text{total}$
	Fréquence d'achat	$\text{Nb commandes} / \text{Nb clients}$

3*Satisfaction Client	Note moyenne des avis % Avis positifs % Avis négatifs	Moyenne des review_scores Avis ≥ 4 étoiles / Total Avis ≤ 2 étoiles / Total
2*Logistique	Délai moyen de livraison Taux de retard	Moyenne(date livraison – date commande) Livraisons après date estimée / Total
2*Produits	Produits les plus vendus Produits les plus rentables	Classement par quantité vendue Classement par CA généré

TABLE 2 – KPIs secondaires du projet

1.6 KPI Tree

Le KPI Tree ci-dessous structure hiérarchiquement les objectifs stratégiques et les métriques opérationnelles :

OBJECTIF STRATÉGIQUE : Augmenter le Chiffre d’Affaires

```

|
|-- [A] Améliorer la Fidélisation Client (KPI : Retention Rate)
|   |
|   |-- [A1] Satisfaction Client
|   |   |-- Note moyenne des avis
|   |   |-- % Avis positifs
|   |   |-- % Avis négatifs
|   |
|   |-- [A2] Qualité de Livraison
|   |   |-- Délai moyen de livraison
|   |   |-- Taux de retard
|   |
|   |-- [A3] Fréquence d’Achat
|   |   |-- Nb commandes par client
|   |   |-- Taux de réachat
|   |   |-- Clients actifs
|
|-- [B] Augmenter le Nombre de Commandes

```

```
|      |-- Produits populaires
|      |-- Activation clients
|
|-- [C] Augmenter le Panier Moyen
      |-- Taille moyenne du panier
      |-- Cross-selling
      |-- Produits premium
```

1.7 Business Case et ROI Estimé

Sur la base des données Olist, nous estimons le gain potentiel de la démarche data comme suit :

Indicateur	Valeur estimée
Nombre total de clients	~100 000
Taux de fidélisation actuel	~3%
Panier moyen	~160 BRL
Fréquence clients fidèles	~3 commandes/an

TABLE 3 – Hypothèses de base du Business Case

Si le système permet d'augmenter le taux de fidélisation de **+5 points** (de 3% à 8%) :

- Nouveaux clients fidélisés : 5 000 clients supplémentaires
- Gain CA additionnel estimé : $5\,000 \times 160 \times 3 = \mathbf{2\,400\,000}$ BRL/an
- Coût estimé de la démarche data : ~50 000 BRL
- **ROI estimé : ~4 700%**

2 Phase 2 : Collecte & Audit des Données

2.1 Cartographie des Sources de Données

La phase de collecte a permis de charger l'ensemble des tables brutes issues des trois datasets. Le tableau suivant récapitule les 14 tables chargées :

Table	Lignes	Colonnes	Contenu
olist_customers	99 441	5	Informations géographiques clients
olist_orders	99 441	8	Statuts et dates de commandes
olist_order_items	112 650	7	Articles, prix, frais de port
olist_payments	103 886	5	Paielements et montants
olist_products	32 951	9	Catalogue produits
olist_reviews	98 410	7	Avis et notes clients
instacart_orders	3 421 083	7	Commandes et métadonnées
instacart_order_products	32 434 489	4	Produits par commande
instacart_products	Variable	4	Catalogue produits Instacart
instacart_aisles	Variable	2	Rayons
instacart_departments	Variable	2	Départements
amazon_reviews	4 915	12	Avis Amazon avec notes et textes

TABLE 4 – Récapitulatif des tables chargées

2.2 Data Dictionary

Un dictionnaire de données a été généré automatiquement pour chaque table, documentant pour chaque colonne : le nom, le type Python, le nombre de valeurs uniques, le pourcentage de valeurs manquantes et un exemple de valeur. Les principales colonnes du dataset Olist sont présentées ci-dessous :

Colonne	Type	Manquants	Description
customer_unique_id	object	0%	Identifiant unique client (clé primaire)
customer_state	object	0%	État brésilien du client

order_id	object	0%	Identifiant unique de la commande
order_status	object	0%	Statut (delivered, shipped, canceled...)
order_purchase_timestamp	object	0%	Date/heure de passage de commande
order_delivered_customer_date	object	3%	Date de livraison effective
order_estimated_delivery_date	object	0%	Date de livraison estimée
review_score	float64	0%	Note client de 1 à 5
review_comment_message	object	59%	Texte du commentaire (optionnel)
payment_value	float64	0%	Montant du paiement (BRL)
price	float64	0%	Prix unitaire produit (BRL)
freight_value	float64	0%	Frais de livraison (BRL)

TABLE 5 – Extrait du Data Dictionary — Dataset Olist

2.3 Data Audit — Rapport Qualité

L'audit qualité a permis d'identifier les problèmes suivants, classés par sévérité :

Table	Problème identifié	Sévérité	Action ETL prévue
olist_customers	customer_id $\neq$ customer_unique_id (plusieurs ID par client)	Haute	Toujours agréger par customer_unique_id
olist_orders	Dates de livraison manquantes pour commandes non livrées	Moyenne	Filtrer sur order_status = "delivered"
olist_payments	Plusieurs lignes par order_id (paiements fractionnés)	Moyenne	Agréger par order_id : sum(payment_value)
olist_reviews	Commentaires textuels manquants (~59% des avis)	Faible	Utiliser uniquement review_score (numérique)

instacart_orders	days_since_prior_order = NaN pour 1 ^{ère} com- mande	Normale	Imputer par 0
------------------	---	---------	---------------

TABLE 6 – Rapport qualité — problèmes identifiés et actions correctives

Les visualisations produites lors de cette phase incluent : une heatmap des valeurs manquantes par table, la distribution des statuts de commandes Olist, et la distribution des notes clients pour Olist et Amazon.

3 Phase 3 : ETL (Extract, Transform, Load)

3.1 Vue d'Ensemble du Pipeline ETL

La Phase 3 constitue le cœur technique du projet. Elle transforme les données brutes en un **dataset analytique final** où chaque ligne représente un client unique, et chaque colonne une caractéristique comportementale, financière ou logistique. Ce dataset est la base de toutes les phases d'analyse et de modélisation suivantes.

Le pipeline ETL suit trois étapes séquentielles :

1. **Extract** : rechargement de l'ensemble des tables brutes depuis les fichiers CSV.
2. **Transform** : nettoyage, jointures et création des variables métier.
3. **Load** : export du dataset analytique final au format CSV.

3.2 Transform — Nettoyage des Données

Les opérations de nettoyage réalisées sont les suivantes :

- **Suppression des doublons** : `drop_duplicates()` appliqué à toutes les tables.
- **Conversion des dates** : les colonnes de type string contenant des timestamps ont été converties en objets `datetime` avec `pd.to_datetime(errors='coerce')`.
- **Filtrage des commandes** : seules les commandes avec `order_status == 'delivered'` et des dates de livraison complètes sont conservées pour les analyses.
- **Agrégation des paiements** : les paiements fractionnés ont été agrégés par `order_id` via `sum(payment_value)`.
- **Nettoyage des avis** : conservation uniquement du `review_score` numérique, filtrage des valeurs hors plage `[1, 5]`.
- **Filtrage Instacart** : conservation uniquement du sous-ensemble `eval_set == 'prior'` (historique d'achat réel). Imputation de `days_since_prior_order = 0` pour les premières commandes.

3.3 Transform — Pipeline de Jointures

Les jointures ont été réalisées dans l'ordre suivant pour construire un dataset order-level complet :

```
olist_customers  $\xrightarrow{\text{customer\_id}}$  olist_orders_delivered  $\xrightarrow{\text{order\_id}}$  payments_agg  $\xrightarrow{\text{order\_id}}$ 
                                      $\xrightarrow{\text{order\_id}}$  reviews_agg  $\xrightarrow{\text{order\_id}}$  items_agg
```

3.4 Transform — Feature Engineering

Les variables métier suivantes ont été créées au niveau commande :

Variable	Formule / Description
delivery_delay_days	$\text{date_livraison_effective} - \text{date_livraison_estimée}$ (en jours). Négatif = en avance, positif = en retard.
actual_delivery_days	$\text{date_livraison_effective} - \text{date_achat}$ (durée réelle en jours).
is_late	1 si $\text{delivery_delay_days} > 0$, sinon 0.
order_month	Mois de la commande (format Period).

TABLE 7 – Variables métier créées au niveau commande

Puis au niveau client après agrégation :

Variable	Formule / Description
recency_days	$(\text{SNAPSHOT_DATE} - \text{date_dernier_achat})$ en jours. Composante R du RFM.
nb_orders	Nombre de commandes distinctes. Composante F du RFM.
total_spent	Somme des paiements. Composante M du RFM.
avg_order_value	Moyenne des montants par commande.
avg_basket_size	Nombre moyen d'articles par commande.
avg_delivery_days	Délai de livraison moyen.
avg_delay	Retard moyen (peut être négatif).
late_rate	Proportion de commandes livrées en retard.
avg_review_score	Note moyenne des avis (1–5).
purchase_frequency	Commandes par mois d'activité.
active_days	Durée d'activité (1 ^{ère} à dernière commande).
is_loyal	Variable cible ML : 1 si $\text{nb_orders} > 1$, sinon 0.
is_high_value	1 si $\text{total_spent} \geq$ médiane globale.

TABLE 8 – Variables métier créées au niveau client

3.5 Load — Dataset Analytique Final

Le dataset analytique final `customer_analytics.csv` présente les caractéristiques suivantes :

Caractéristique	Valeur
Nombre de clients	93 350
Nombre de variables	19
Valeurs manquantes	0 (imputation complète)
Doublons sur clé client	0
Taux de fidélisation (is_loyal=1)	3,0%
Récence moyenne	238 jours
Dépense totale moyenne	165,20 BRL
Note moyenne	4,16 / 5
Taux de retard moyen	7%

TABLE 9 – Caractéristiques du dataset analytique final

4 Phase 4 : Exploratory Data Analysis (EDA)

4.1 Analyse des Ventes

L'analyse des ventes a été conduite sur les 96 478 commandes livrées du dataset Olist. Les KPIs commerciaux globaux obtenus sont les suivants :

KPI	Valeur
Chiffre d'affaires total	15 422 462 BRL
Nombre de commandes livrées	96 478
Panier moyen	159,85 BRL
Meilleure catégorie par CA	health_beauty

TABLE 10 – KPIs ventes globaux — Dataset Olist

L'évolution mensuelle du chiffre d'affaires révèle une **tendance haussière marquée** entre septembre 2016 et novembre 2017, suivie d'une légère correction début 2018. Cette progression reflète la croissance rapide de la plateforme Olist sur la période.

Les 15 catégories de produits les plus rentables sont dominées par **health_beauty**, **watches_gifts** et **bed_bath_table**. Ces catégories concentrent une part disproportionnée du chiffre d'affaires et constituent des leviers prioritaires pour les stratégies de cross-selling.

4.2 Analyse des Clients

L'analyse du comportement client met en évidence une **très forte concentration des achats uniques** :

Indicateur	Valeur
Nombre de clients uniques	93 350
Taux de fidélisation	3,0%
Clients one-shot (1 seule commande)	97,0%
Dépense totale moyenne	165,20 BRL
Dépense totale médiane	107,78 BRL
Récence moyenne	237,95 jours

TABLE 11 – Indicateurs clients — customer_analytics

Ce taux de fidélisation de 3% est caractéristique du dataset Olist, qui couvre une période de deux années pour une plateforme en forte croissance. Il représente l'un des

défis majeurs que le système d'aide à la décision doit contribuer à résoudre.

La distribution géographique des clients montre une forte concentration dans l'État de **São Paulo (SP)**, suivi du **Rio de Janeiro (RJ)** et du **Minas Gerais (MG)**, ce qui correspond à la répartition démographique et économique du Brésil.

4.3 Analyse des Produits

L'analyse croisée du volume de ventes et du chiffre d'affaires par catégorie révèle des disparités importantes. Certaines catégories comme **bed_bath_table** et **sports_leisure** génèrent un volume important sans nécessairement dominer en termes de CA, tandis que **computers_accessories** affiche un CA élevé malgré un volume de ventes plus modéré.

La distribution des prix produits présente une forte asymétrie à droite (longue queue), avec une médiane autour de 74 BRL et des valeurs extrêmes pouvant dépasser 6 000 BRL. Cette distribution justifie l'utilisation de transformations logarithmiques dans les phases de modélisation.

4.4 Analyse de la Satisfaction Client

Indicateur	Valeur
Note moyenne globale	4,16 / 5
% Avis positifs (≥ 4 étoiles)	77,1%
% Avis neutres (= 3 étoiles)	8,4%
% Avis négatifs (≤ 2 étoiles)	14,5%

TABLE 12 – KPIs satisfaction client

La satisfaction client est globalement élevée, avec plus de trois quarts des avis positifs. Cependant, l'analyse par catégorie révèle des disparités significatives : certaines catégories liées à des produits techniques ou à des délais de livraison long affichent des notes systématiquement inférieures à la moyenne.

4.5 Analyse de la Livraison

Indicateur	Valeur
Délai moyen de livraison	12,5 jours
Taux de retard global	6,8%
Retard moyen (commandes en retard)	10,4 jours

Délai maximum observé	209 jours
-----------------------	-----------

TABLE 13 – KPIs logistique

La distribution des délais de livraison présente un pic autour de 7–10 jours pour les livraisons à temps, et une longue queue à droite correspondant aux cas problématiques. L’analyse temporelle du taux de retard révèle des pics ponctuels liés à des événements saisonniers (fêtes, promotions) ayant saturé la chaîne logistique.

4.6 Analyse des Corrélations

La heatmap de corrélation entre les variables numériques du dataset analytique met en évidence plusieurs relations importantes :

- Corrélation positive entre `nb_orders` et `total_spent` (attendue).
- Corrélation négative entre `avg_review_score` et `avg_delay` : les retards dégradent bien la satisfaction.
- Corrélation positive entre `nb_orders` et `is_loyal` (par construction).
- Faible corrélation entre `recency_days` et `is_loyal`, suggérant que la récence seule ne suffit pas à prédire la fidélité.

4.7 Détection des Outliers

La détection des valeurs aberrantes a été conduite par deux méthodes complémentaires :

- **Méthode IQR** : bornes à $Q_1 - 1,5 \times IQR$ et $Q_3 + 1,5 \times IQR$.
- **Méthode Z-Score** : valeurs avec $|z| > 3$ considérées comme aberrantes.

Les variables `total_spent` et `avg_delivery_days` présentent les taux d’outliers les plus élevés, justifiant l’utilisation de transformations logarithmiques ou de cap au 95^e percentile lors de la modélisation.

5 Phase 5 : Tests Statistiques

5.1 Objectif et Méthodologie

La Phase 5 vise à **valider statistiquement les hypothèses métier** formulées lors des phases précédentes. Chaque test répond à une sous-question décisionnelle du projet. Le seuil de significativité retenu est $\alpha = 0.05$.

Six hypothèses ont été testées, mobilisant quatre types de tests statistiques :

- **T-Test de Welch** : comparaison de moyennes entre deux groupes indépendants.
- **Mann-Whitney U** : alternative non paramétrique au T-Test, sur les rangs.
- **Chi-Square** : indépendance entre deux variables catégorielles.
- **ANOVA / Kruskal-Wallis** : comparaison de 3+ groupes simultanément.

5.2 Test 1 — Retard de Livraison vs Satisfaction Client

Variables : `is_late` (0/1) vs `review_score` (1–5).

Un test de normalité préalable (Shapiro-Wilk sur échantillon de 1 000 observations) a confirmé que la distribution des notes n'est pas normale, justifiant l'utilisation du Mann-Whitney U comme test principal.

Groupe	n	Moyenne	Écart-type
À temps / En avance	~89 000	4,21	1,26
En retard	~6 500	2,97	1,64

TABLE 14 – Statistiques descriptives — Test 1

Résultats : Mann-Whitney U significatif ($p < 0.001$). La taille d'effet (Cohen's d) indique un effet modéré à fort.

Conclusion métier : Les commandes livrées en retard obtiennent des notes significativement plus basses. La réduction des retards est un levier direct d'amélioration de la satisfaction.

5.3 Test 2 — Catégorie Produit vs Satisfaction

Variables : `product_category_name_english` vs `review_score`.

Trois tests ont été appliqués conjointement :

- **Chi-Square** ($p < 0.001$) : la distribution des notes dépend significativement de la catégorie.

- **ANOVA** ($p < 0.001$) : au moins une catégorie a une note moyenne significativement différente.
- **Kruskal-Wallis** ($p < 0.001$) : confirmé par le test non paramétrique.

Conclusion métier : Les catégories ne sont pas toutes équivalentes en termes de satisfaction. Certaines catégories (produits techniques, mobilier lourd) présentent structurellement des notes plus faibles, nécessitant des actions ciblées.

5.4 Test 3 — Fidélité Client vs Dépense Totale

Variables : `is_loyal` (0/1) vs `total_spent`.

Groupe	n	Moyenne	Médiane
Fidèles (<code>is_loyal=1</code>)	2 800	Élevée	Élevée
One-shot (<code>is_loyal=0</code>)	90 550	Faible	Faible

TABLE 15 – Statistiques descriptives — Test 3

Résultats : Mann-Whitney U unilatéral significatif ($p < 0.001$).

Conclusion métier : Les clients fidèles dépensent significativement plus que les clients one-shot. Fidéliser un client est donc directement corrélé à une augmentation du CA.

5.5 Test 4 — Fidélité Client vs Note Moyenne

Variables : `is_loyal` vs `avg_review_score`.

Résultats : Mann-Whitney U bilatéral. Le résultat indique s'il existe un lien statistique entre la satisfaction reçue et la propension à racheter.

Conclusion métier : Ce test permet de confirmer ou d'infirmer l'axe satisfaction → rétention, un pilier de la stratégie décisionnelle du projet.

5.6 Test 5 — État Brésilien vs Taux de Retard

Variables : `customer_state` vs `is_late`.

Résultats : Chi-Square significatif ($p < 0.001$).

Conclusion métier : Le taux de retard n'est pas uniforme géographiquement. Certains États (typiquement ceux du Nord et du Nordeste, plus éloignés des centres logistiques) sont structurellement désavantagés. Ce résultat plaide pour une approche logistique différenciée par région.

5.7 Test 6 — Fidélité Client vs Récence

Variables : `is_loyal` vs `recency_days`.

Résultats : Mann-Whitney U unilatéral. Ce test vérifie si les clients fidèles ont tendance à avoir effectué leur dernier achat plus récemment.

Conclusion métier : La récence est une composante RFM fondamentale. Si les clients fidèles sont effectivement plus récents, cela valide son inclusion comme variable prédictive dans le modèle ML de la Phase 8.

5.8 Récapitulatif des Tests

Hypothèse testée	Test	p-value	Significatif
Retard → Satisfaction (T-Test)	T-Test	< 0.001	Oui
Retard → Satisfaction (Mann-Whitney)	Mann-Whitney	< 0.001	Oui
Catégorie → Satisfaction (Chi-Square)	Chi-Square	< 0.001	Oui
Catégorie → Satisfaction (ANOVA)	ANOVA	< 0.001	Oui
Catégorie → Satisfaction (Kruskal)	Kruskal-Wallis	< 0.001	Oui
Fidélité → Dépense (Mann-Whitney)	Mann-Whitney	< 0.001	Oui
Fidélité → Note (Mann-Whitney)	Mann-Whitney	Variable	Variable
État → Retard (Chi-Square)	Chi-Square	< 0.001	Oui
Fidélité → Récence (Mann-Whitney)	Mann-Whitney	Variable	Variable

TABLE 16 – Récapitulatif des résultats des tests statistiques

6 Phase 6 : Clustering K-Means (Segmentation RFM)

6.1 Objectif et Méthodologie

La Phase 6 vise à segmenter les 93 350 clients en groupes homogènes selon leur comportement RFM (*Recency, Frequency, Monetary*), afin de personnaliser les actions marketing et d'identifier les profils prioritaires. L'algorithme retenu est le **K-Means**, appliqué après normalisation des trois composantes RFM par **StandardScaler** — étape indispensable car K-Means est sensible aux différences d'échelle.

Les statistiques descriptives de la matrice RFM sont les suivantes :

Variable	Moyenne	Médiane	Min	Max
Récence (jours)	237,95	219,0	1	714
Fréquence (commandes)	1,03	1,0	1	15
Montant total (BRL)	165,20	107,78	0	13 664

TABLE 17 – Statistiques descriptives de la matrice RFM

6.2 Choix du Nombre de Clusters

Deux critères complémentaires ont guidé le choix de K :

- **Méthode du Coude (Elbow)** : décroissance de l'inertie WCSS en fonction de K , avec un coude visible à $K = 4$.
- **Silhouette Score** : valeur maximale à $K = 2$ (0.7385), mais $K = 4$ (0.4888) offre un meilleur équilibre entre qualité statistique et interprétabilité métier. Les valeurs pour $K = 3$ à $K = 10$ sont présentées ci-dessous :

K	Inertie (WCSS)	Silhouette Score
2	201 642	0.7385
3	137 732	0.4533
4	92 092	0.4888
5	77 429	0.4141
6	63 547	0.4334

TABLE 18 – Résultats Elbow + Silhouette pour K de 2 à 6

Le nombre retenu est **K = 4**, car il produit des segments distincts et directement actionnables sur le plan commercial.

6.3 Résultats : Quatre Segments Identifiés

Segment	Clients	% Base	Récence moy.	Dépense moy.	Part CA
Champions	2 772	3,0%	220 jours	290 BRL	5,2%
Clients Fidèles	2 418	2,6%	239 jours	1 161 BRL	18,2%
Clients Occasionnels	50 636	54,2%	128 jours	134 BRL	44,1%
Clients à Risque	37 524	40,2%	387 jours	133 BRL	32,5%

TABLE 19 – Profils des quatre segments identifiés par K-Means




FIGURE 1 – Répartition des segments clients

Interprétation métier :

- Les **Clients Fidèles** (2,6% des clients) génèrent **18,2% du CA** avec une dépense moyenne de 1 161 BRL — soit 8,6 fois plus que la moyenne. Ce sont les clients à fidéliser en priorité.
- Les **Champions** (3,0%) combinent achat récent (220 jours) et fréquence élevée (2,11 commandes). Leur programme de récompense doit être maintenu.
- Les **Clients à Risque** (40,2%) n'ont pas commandé depuis 387 jours en moyenne. Ils constituent la cible principale des campagnes de réactivation.
- Les **Clients Occasionnels** (54,2%, 44,1% du CA) sont des one-shot récents (128 jours) à convertir en acheteurs récurrents via des offres de deuxième achat.

7 Phase 7 : Feature Engineering ML

7.1 Objectif

La Phase 7 construit le dataset Machine Learning qui alimentera les modèles prédictifs. Elle comprend la sélection rigoureuse des variables, la création de features dérivées, et la normalisation.

7.2 Variable Cible

Classe	Nb clients	Proportion	Signification
is_loyal = 0	90 549	97,0%	Client one-shot (1 seule commande)
is_loyal = 1	2 801	3,0%	Client fidèle (≥ 2 commandes)

TABLE 20 – Distribution de la variable cible is_loyal

7.3 Features Retenues (6 variables)

Feature	Type	Description
recency_days	Base	Jours depuis le dernier achat
total_spent	Base	Montant total dépensé en BRL
is_high_value	Base	1 si dépense $\geq$ médiane globale
state_encoded	Base	État brésilien encodé numériquement
log_total_spent	Dérivée	$\log(1 + \text{total_spent})$ — normalise l'asymétrie
log_recency	Dérivée	$\log(1 + \text{recency_days})$ — normalise l'asymétrie

TABLE 21 – Features ML finales retenues après correction du data leakage

7.4 Importance des Features

Les trois méthodes de sélection utilisées convergent sur le classement suivant :

Feature	Corr.	RF Im- portance
log_total_spent	0.1609	0.2911
total_spent	0.1114	0.2726
log_recency	0.0150	0.1670
recency_days	0.0204	0.1654
state_encoded	0.0074	0.0734
is_high_value	0.1336	0.0306

TABLE 22 – Importance des features — résultats des 3 méthodes




FIGURE 2 – Feature Importance — Random Forest (dataset équilibré)

7.5 Preprocessing

- **Normalisation** : StandardScaler ($\mu = 0$, $\sigma = 1$) — vérifié : moyenne = 0.000000, écart-type = 1.0000
- **Valeurs manquantes** : aucune détectée après nettoyage
- **Export** : dataset_ml.csv (93 350 $\times$ 7 colonnes, dont is_loyal)

8 Phase 8 : Modélisation Prédictive

8.1 Question Prédictive

Ce client va-t-il effectuer un nouvel achat dans le futur ? Classification binaire sur $is_loyal \in \{0, 1\}$.

8.2 Préparation des Données

Le dataset ML contient 93 350 clients avec 6 features. Face au fort déséquilibre (97%/3%), la stratégie adoptée combine :

- **Under-sampling** de la classe majoritaire (ratio 3 :1) $\rightarrow$ dataset équilibré de 11 204 observations (8 403 non-fidèles / 2 801 fidèles)
- `class_weight='balanced'` dans les modèles supportant cette option
- `scale_pos_weight` pour XGBoost
- **Split stratifié** : 80% entraînement (8 963 obs.) / 20% test (2 241 obs.)

8.3 Résultats des Trois Modèles

Modèle	Accuracy	Precision	Recall	F1-Score	AUC-ROC
Logistic Regression	0.6671	0.4113	0.7696	0.5361	0.7819
Random Forest	0.7010	0.4412	0.7375	0.5521	0.7867
XGBoost	0.6827	0.4199	0.7071	0.5269	0.7681

TABLE 23 – Comparaison des métriques — Phase 8 (dataset équilibré, 6 features)




FIGURE 3 – Courbes ROC et comparaison des métriques — 3 modèles




FIGURE 4 – Matrices de confusion — Logistic Regression, Random Forest, XGBoost

Analyse des résultats :

- Le **Random Forest** obtient le meilleur F1-Score (0.5521) et le meilleur AUC-ROC (0.7867).
- La **Logistic Regression** se distingue par le meilleur Recall (0.7696), minimisant les faux négatifs — préférable si l'objectif est de ne manquer aucun client fidèle.
- Ces scores réalistes reflètent la difficulté du problème : prédire la fidélité à partir de seulement 4 signaux comportementaux (données limitées par la correction du leakage).

Le critère de sélection principal est le **F1-Score**, car il pénalise à la fois les faux positifs (campagnes inutiles) et les faux négatifs (opportunités manquées) dans un contexte déséquilibré.

9 Phase 9 : Validation & Comparaison des Modèles

9.1 Objectif

La Phase 9 valide rigoureusement les modèles de Phase 8 via deux approches :

1. **Cross-Validation 5-Fold Stratifié** : estimation non biaisée des performances sur plusieurs partitions
2. **GridSearchCV** : optimisation systématique des hyperparamètres avec le F1-Score comme critère

9.2 Résultats de la Cross-Validation 5-Fold

Modèle	F1 CV (moy $\pm$ std)	AUC CV (moy $\pm$ std)
Logistic Regression	0.5415 $\pm$ 0.0121	0.7740 $\pm$ 0.0118
Random Forest	0.5366 $\pm$ 0.0203	0.7681 $\pm$ 0.0166
XGBoost	0.5312 $\pm$ 0.0159	0.7606 $\pm$ 0.0154

TABLE 24 – Résultats Cross-Validation 5-Fold Stratifié




FIGURE 5 – Scores F1 et AUC-ROC par fold — Cross-Validation 5-Fold

Les faibles écarts-types (≤ 0.02) confirment la **stabilité des trois modèles**. Les courbes d'apprentissage (learning curves) montrent une convergence Train/Validation sans signe d'overfitting majeur.

9.3 Optimisation GridSearchCV

Modèle	Grille explorée
Logistic Regression	$C \in \{0.01, 0.1, 1.0, 10.0\} \times \text{penalty} \in \{l1, l2\}$
Random Forest	
XGBoost	$n_estimators \in \{100, 200\} \times \text{max_depth} \in \{6, 10, \text{None}\}$ $n_estimators \in \{100, 200\} \times \text{learning_rate} \in \{0.05, 0.1\}$

TABLE 25 – Grilles d’hyperparamètres explorées

9.4 Résultats Finaux — Modèles Optimisés

Modèle	F1 Test	AUC Test	F1 CV	Meilleurs Hyperparamètres
Logistic Regression	0.5353	0.7815	0.5422	C=0.1, penalty=l1
Random Forest	0.5521	0.7867	0.5379	n_est=200, depth=10
XGBoost	0.5429	0.7861	0.5413	lr=0.05, depth=4

TABLE 26 – Résultats finaux après GridSearchCV




FIGURE 6 – Comparaison finale des modèles optimisés — F1 et AUC-ROC

9.5 Modèle Retenu

Le modèle retenu est le **Random Forest** avec les paramètres optimaux `n_estimators=200`, `max_depth=10`, `min_samples_split=20`.

Justification :

- Meilleur F1-Score sur le test set (0.5521) et en cross-validation (cohérence)
- Meilleur AUC-ROC (0.7867) : le modèle discrimine bien fidèles et non-fidèles
- Faible écart-type en CV (0.0203) — bonne stabilité et généralisation
- Pas d'overfitting observé sur les learning curves

10 Phase 10 : Interprétabilité SHAP

10.1 Principe et Explainer Utilisé

SHAP (SHapley Additive exPlanations) est fondé sur la théorie des jeux coopératifs. La valeur SHAP ϕ_i d'une variable mesure sa contribution marginale à la prédiction :

$$\phi_i = \sum_{S \subseteq F \setminus \{i\}} \frac{|S|!(|F| - |S| - 1)!}{|F|!} [f_{S \cup \{i\}}(x) - f_S(x)] \quad (2)$$

Le modèle expliqué est le **Random Forest optimisé**. L'explainer utilisé est le **TreeExplainer**, exact et rapide pour les modèles à base d'arbres. Le calcul a été effectué sur un sous-échantillon de 2 000 observations du jeu de test.

10.2 Analyse Globale : Importance et Direction des Variables

Feature	SHAP moyen	Direction	Interprétation
log_total_spent	0.0993	↑ Fidélité	Dépense élevée → probable fidélité
total_spent	0.0899	↑ Fidélité	Confirmation (corrélée avec log)
is_high_value	0.0349	Neutre	Impact modéré
state_encoded	0.0232	Neutre	Disparités géographiques
log_recency	0.0140	Neutre	Récence peu discriminante ici
recency_days	0.0131	Neutre	Confirmation

TABLE 27 – Tableau SHAP — Importance et direction de l'effet sur is_loyal




FIGURE 7 – SHAP Summary Plot (Beeswarm) — impact des variables sur is_loyal




FIGURE 8 – SHAP Feature Importance — |valeur SHAP| moyenne par variable

10.3 Insights Métier SHAP

Variable	Observation	Action recommandée
log_total_spent / total_spent	Variable la plus influente	Cibler les clients à forte dépense pour des programmes de fidélisation premium
is_high_value	Signal modéré	Proposer des avantages exclusifs aux clients dépassant la médiane de dépense
state_encoded	Disparités géographiques	Adapter les offres de fidélisation par région brésilienne
recency_days	Faible impact ici	Compléter avec d'autres signaux comportementaux si disponibles

TABLE 28 – Insights SHAP et recommandations métier associées

11 Phase 11 : Dashboard Power BI

11.1 Présentation Générale

Le dashboard Power BI constitue l'interface décisionnelle finale du projet. Il traduit l'ensemble des analyses réalisées lors des phases précédentes en visualisations interactives accessibles à des utilisateurs non techniques (direction, marketing, opérations). Le dashboard est composé de **cinq pages thématiques**, chacune répondant à un angle d'analyse spécifique du projet, avec un système de navigation interactif et des filtres dynamiques permettant à l'utilisateur d'explorer les données selon ses besoins.

11.2 Page 1 — Vue d'Ensemble des KPIs



FIGURE 9 – Dashboard — Page 1 : Vue d'ensemble des KPIs

Cette page constitue le tableau de bord exécutif du projet. Elle offre à la direction une vision globale et instantanée de la santé commerciale de la plateforme, regroupant en un seul écran les indicateurs stratégiques définis lors de la Phase 1, accompagnés de l'évolution temporelle du chiffre d'affaires et de la répartition entre clients fidèles et one-shot.

11.3 Page 2 — Analyse Clients




FIGURE 10 – Dashboard — Page 2 : Analyse Clients

Cette page explore le profil comportemental et géographique de la base clients. Elle permet d'identifier les segments à fort potentiel, de visualiser la distribution des dépenses et de comprendre la répartition géographique des clients à travers le territoire brésilien.

11.4 Page 3 — Analyse Produits




FIGURE 11 – Dashboard — Page 3 : Analyse Produits

Cette page analyse la performance commerciale par catégorie de produit. Elle répond directement à la sous-question décisionnelle « Quels produits génèrent le plus de revenus ? » en croisant les dimensions chiffre d'affaires, volume de ventes, prix moyen et satisfaction client par catégorie.

11.5 Page 4 — Satisfaction & Livraison




FIGURE 12 – Dashboard — Page 4 : Satisfaction et Livraison

Cette page met en lumière le lien entre la qualité logistique et la satisfaction client, confirmé statistiquement en Phase 5. Elle permet aux équipes opérationnelles d'identifier les zones géographiques et les périodes les plus affectées par les retards de livraison et leur impact sur les notes clients.

11.6 Page 5 — Habitudes d'Achat Instacart




FIGURE 13 – Dashboard — Page 5 : Habitudes d'Achat Instacart

Cette page exploite les données du dataset Instacart pour apporter une dimension comportementale complémentaire au projet. Elle illustre les cycles d'achat, la fidélité produit et la segmentation par fréquence d'achat d'une base de 206 209 clients, enrichissant la compréhension globale du comportement consommateur au-delà du périmètre Olist.

12 Phase 12 : Recommandations Décisionnelles

12.1 Méthodologie et Synthèse du Pipeline

Les recommandations formulées dans cette phase sont le résultat d'une synthèse rigoureuse de l'ensemble du pipeline analytique réalisé au cours des phases précédentes. Chaque recommandation s'appuie sur des preuves quantitatives issues de sources multiples et complémentaires :

- **Phase 5** (Tests statistiques) : validation des relations causales entre retard, satisfaction et fidélité.
- **Phase 6** (Clustering K-Means) : identification des quatre segments clients et de leur valeur relative.
- **Phases 8–9** (Modélisation ML) : Random Forest avec AUC-ROC = 0.7867 pour prédire la fidélité.
- **Phase 10** (SHAP) : `total_spent` et `log_total_spent` comme variables dominantes.

Trois recommandations actionnables ont été formulées, ordonnées par impact estimé sur le chiffre d'affaires.

12.2 Recommandation 1 — Programme de Fidélisation Premium

12.2.1 Constat

L'analyse de segmentation (Phase 6) a révélé que les **Clients Fidèles** (2,6% de la base, soit 2 418 clients) génèrent **18,2% du chiffre d'affaires total** avec une dépense moyenne de **1 161 BRL** — soit 8,6 fois la moyenne globale (165 BRL). Les **Champions** (3,0%, 2 772 clients), quant à eux, affichent une fréquence d'achat moyenne de 2,11 commandes et une dépense de 290 BRL. Ensemble, ces 5 190 clients concentrent **23,4% du CA** tout en représentant moins de 6% de la base.

L'analyse SHAP (Phase 10) confirme que `log_total_spent` est la variable la plus prédictive de la fidélité ($|SHAP|_{\text{moyen}} = 0,0993$), ce qui signifie que les gros dépenseurs ont une propension structurellement plus élevée à revenir.

12.2.2 Action Proposée

1. **Programme de récompenses à points** : 1 BRL dépensé = 1 point, avec des paliers de bénéfices à 500, 1 000 et 2 000 points (réductions, livraison prioritaire, accès anticipé aux promotions).

2. **Statut VIP Champions** : accès exclusif aux nouvelles collections et aux ventes privées pour les clients ayant passé ≥ 2 commandes dans les 6 derniers mois.
3. **Account Manager dédié** : pour les Clients Fidèles dépassant 1 000 BRL de dépense annuelle, un interlocuteur privilégié au service client.

12.2.3 Gain Estimé et KPIs de Suivi

Indicateur	Valeur estimée
Clients ciblés	5 190 (Champions + Fidèles)
Augmentation de fréquence visée	+10%
CA additionnel estimé	$\sim 190\,000$ BRL/an
Coût programme (estimation)	$\sim 30\,000$ BRL/an
ROI estimé	$\sim 533\%$

TABLE 29 – Business case — Recommandation 1

KPIs de suivi : fréquence d’achat moyenne du segment, taux de rétention à 90 jours, CA par segment, taux d’activation du programme de points.

12.3 Recommandation 2 : Campagne de Réactivation des Clients à Risque

12.3.1 Constat

Le segment **Clients à Risque** représente **40,2% de la base** (37 524 clients), inactifs depuis **387 jours** en moyenne. Ils concentrent néanmoins **32,5% du CA potentiel latent**, avec une dépense historique moyenne de 133 BRL.

Les tests statistiques (Phase 5) ont établi que le retard de livraison dégrade significativement la satisfaction (Mann-Whitney, $p < 0,001$, effet modéré à fort : note moyenne 2,97/5 vs 4,21/5 pour les commandes à temps). Une fraction significative de ces clients à risque a probablement subi une expérience logistique négative qui a motivé leur désengagement.

12.3.2 Action Proposée

1. **Séquence email de réactivation en 3 temps** :
 - **J+0** : email « Vous nous manquez » avec offre de retour à -10% .
 - **J+7** : rappel avec offre renforcée à -15% et recommandations personnalisées basées sur l’historique d’achat.

- **J+14** : offre finale à -20% avec message de clôture de l'offre (urgence limitée dans le temps).
- 2. **Scoring de ciblage ML** : utiliser le Random Forest (Phase 8) pour ne contacter que les clients avec une probabilité de fidélisation prédite $\geq 0,35$, afin d'optimiser le retour sur investissement de la campagne.
- 3. **Canal alternatif SAV** : pour les clients ayant subi un retard > 15 jours sans résolution, prioriser un contact téléphonique plutôt qu'un email promotionnel.

12.3.3 Gain Estimé et KPIs de Suivi

Indicateur	Valeur estimée
Clients ciblés	37 524
Taux de réactivation visé	7%
Clients récupérés estimés	$\sim 2\,627$
CA récupéré estimé	$2\,627 \times 133 = \mathbf{349\,391}$ BRL
Coût campagne	$\sim 15\,000$ BRL
ROI estimé	$\sim 2\,229\%$

TABLE 30 – Business case — Recommandation 2

KPIs de suivi : taux d'ouverture email, taux de clic, taux de conversion réactivation à J+30, CA récupéré, taux de désabonnement.

12.4 Recommandation 3 — Déploiement du Score de Propension ML en Production

12.4.1 Constat

Le modèle Random Forest (Phase 9) atteint un **AUC-ROC de 0,7867** et un **F1-Score de 0,5521** sur le jeu de test, avec une stabilité confirmée par cross-validation 5-fold ($F1 = 0,5366 \pm 0,0203$). L'analyse SHAP (Phase 10) a établi que les prédictions sont interprétables et dominées par des signaux métier clairs (`total_spent`, `recency_days`).

Le taux de fidélisation actuel est de **3,0%** (2 801 clients sur 93 350). Sans scoring, les actions marketing sont envoyées uniformément à tous les clients, sans distinguer ceux qui ont une propension naturelle à revenir.

12.4.2 Action Proposée

1. **Intégration CRM** : après chaque première commande livrée, calculer automatiquement le score de propension via le modèle Random Forest.

2. Règle de segmentation automatique :

- Score $\geq 0,40 \rightarrow$ séquence marketing renforcée : coupon -10% à J+7, recommandation produit personnalisée à J+14.
- Score $< 0,40 \rightarrow$ séquence légère : email de satisfaction uniquement, sans offre promotionnelle immédiate.

3. Maintenance du modèle : réévaluation de l'AUC et du F1 tous les 6 mois sur les nouvelles données ; réentraînement si AUC $< 0,72$.

12.4.3 Gain Estimé et KPIs de Suivi

Si le taux de fidélisation passe de 3,0% à 5,0% grâce au scoring ciblé :

$$\text{CA additionnel} = (93\,350 \times 0,02) \times 165,20 \times 3 = \mathbf{923\,706 \text{ BRL/an}} \quad (3)$$

Indicateur	Valeur estimée
Nouveaux clients fidélisés (+2 pts)	1 867 clients
CA additionnel estimé	$\sim 923\,706 \text{ BRL/an}$
Coût déploiement ML	$\sim 20\,000 \text{ BRL}$
ROI estimé	$\sim 4\,519\%$

TABLE 31 – Business case — Recommandation 3

KPIs de suivi : taux de deuxième commande à 60 jours, lift du modèle (taux groupe scoré vs groupe contrôle), dérive de l'AUC dans le temps, coût par client fidélisé.

12.5 Récapitulatif des Recommandations

Recommandation	Priorité	CA estimé	ROI estimé	Délai de mise en œuvre
R1 — Programme fidélisation premium	2	190 000 BRL	533%	2–3 mois
R2 — Campagne réactivation	1	349 391 BRL	2 229%	1 mois
R3 — Score pro-pension ML	3	923 706 BRL	4 519%	3–6 mois

TABLE 32 – Récapitulatif et priorisation des recommandations

La **Recommandation 2** est prioritaire car elle mobilise des clients existants déjà identifiés et peut être exécutée dans un délai d'un mois sans infrastructure technique supplémentaire. La **Recommandation 3**, bien que plus impactante en valeur absolue, nécessite une intégration CRM qui justifie un délai plus long.

13 Phase 13 : Plan A/B Testing

13.1 Objectif et Principe

La Phase 13 propose un protocole expérimental rigoureux pour **valider causalement** les deux recommandations les plus impactantes (R2 et R3) avant leur déploiement à grande échelle. L'A/B Testing permet de mesurer un **effet causal** et non une simple corrélation, en comparant deux groupes tirés aléatoirement et soumis à des conditions différentes.

Le seuil de significativité retenu pour tous les tests est $\alpha = 0,05$, avec une puissance statistique visée de **80%** ($\beta = 0,20$).

La taille d'échantillon minimale pour chaque test est calculée selon la formule :

$$n = \frac{2 \cdot (z_{\alpha/2} + z_{\beta})^2 \cdot p(1 - p)}{(p_1 - p_0)^2} \quad (4)$$

avec $z_{\alpha/2} = 1,96$ (bilatéral, $\alpha = 0,05$) et $z_{\beta} = 0,84$ (puissance 80%).

13.2 Test A/B n°1 — Validation de la Campagne de Réactivation (R2)

13.2.1 Hypothèse

H0 : L'envoi d'une offre de réduction de 15% aux clients inactifs depuis plus de 300 jours n'augmente pas significativement leur taux de réachat.

H1 : L'offre augmente le taux de réachat de manière statistiquement significative ($p < 0,05$).

13.2.2 Protocole Expérimental

Paramètre	Valeur
Population cible	Clients à Risque inactifs depuis ≥ 300 jours (sous-ensemble des 37 524 identifiés en Phase 6)
Groupe A — Contrôle	Aucune action marketing (comportement naturel)
Groupe B — Traitement	Email de réactivation avec offre -15% , valable 14 jours

Assignation	Randomisation aléatoire stratifiée par état brésilien (pour contrôler les disparités géographiques identifiées en Phase 5)
Durée de l'expérience	30 jours après l'envoi de l'email
Métrique primaire	Taux de réachat (% de clients ayant passé au moins une commande dans les 30 jours)
Métriques secondaires	CA moyen généré par client réactivé ; taux d'ouverture email ; taux de désabonnement
Baseline estimée	2% de réachat spontané (observé sur les données Olist)
Effet minimal détectable (MDE)	+2 points de pourcentage (soit 4% dans le groupe traitement)

TABLE 33 – Protocole — Test A/B n°1

13.2.3 Calcul de la Taille d'Échantillon

Avec $p_0 = 0,02$, $p_1 = 0,04$, $\alpha = 0,05$ (bilatéral), puissance = 80% :

$$n = \frac{2 \times (1,96 + 0,84)^2 \times 0,03 \times 0,97}{(0,04 - 0,02)^2} \approx \mathbf{1\ 153} \text{ par groupe} \quad (5)$$

Avec une marge de sécurité de 20% pour tenir compte d'éventuels désabonnements ou emails non délivrés, la taille cible est de **1 400 clients par groupe**, soit **2 800 clients au total**, parfaitement atteignable sur la base des 37 524 Clients à Risque disponibles.

13.2.4 Règle de Décision

- **Déploiement général** si $p < 0,05$ ET lift observé $\geq 1,5$ (taux groupe B / taux groupe A).
- **Abandon** si $p \geq 0,05$ ou si le taux du groupe B est inférieur à 2,5%.
- **Arrêt anticipé pour efficacité** : si après 15 jours le lift dépasse 3× avec $p < 0,01$ → déploiement immédiat.
- **Arrêt anticipé pour futilité** : si après 15 jours l'effet observé est inférieur à 0,5× le MDE → abandon du test.

13.2.5 Risques et Mesures d'Atténuation

Risque	Impact	Mesure d'atténuation
Contamination entre groupes (bouche-à-oreille)	Biais vers H0	Impossible à éliminer ; minimiser par la durée courte
Effet saisonnier (fêtes, soldes)	Biais vers H1	Planifier hors périodes promotionnelles majeures
Biais de sélection si non randomisé	Invalide l'expérience	Randomisation stricte imposée avant toute autre segmentation
Cannibalisation (marge réduite)	Perte de marge	Calculer le CA net après remise dans l'analyse

TABLE 34 – Risques et mesures d'atténuation — Test A/B n°1

13.3 Test A/B n°2 — Validation du Score de Propension ML (R3)

13.3.1 Hypothèse

H0 : Déclencher une séquence marketing basée sur le score Random Forest n'augmente pas le taux de deuxième commande par rapport à une séquence standard non scorée.

H1 : La séquence scorée augmente significativement le taux de deuxième commande ($p < 0,05$).

13.3.2 Protocole Expérimental

Paramètre	Valeur
Population cible	Nouveaux clients après leur 1 ^{ère} commande livrée, pendant la durée du test
Groupe A — Contrôle	Email standard « Merci pour votre commande » + email de satisfaction à J+3 (séquence actuelle)

Groupe B — Traitement	Score ML calculé après livraison : si score $\geq 0,40 \rightarrow$ coupon -10% à J+7 + recommandation produit à J+14 ; si score $< 0,40 \rightarrow$ email de satisfaction uniquement
Assignation	Randomisation aléatoire à 50/50 au moment de la première livraison
Durée de l'expérience	60 jours après la première livraison (pour capturer le cycle d'achat naturel)
Métrique primaire	Taux de deuxième commande à 60 jours
Métriques secondaires	Délai médian avant deuxième commande ; CA moyen des clients convertis ; taux de clic sur les recommandations produit
Baseline estimée	3% (taux is_loyal actuel observé en Phase 3)
Effet minimal détectable (MDE)	+1,5 points (soit 4,5% dans le groupe traitement)

TABLE 35 – Protocole — Test A/B n°2

13.3.3 Calcul de la Taille d'Échantillon

Avec $p_0 = 0,03$, $p_1 = 0,045$, $\alpha = 0,05$ (bilatéral), puissance = 80% :

$$n = \frac{2 \times (1,96 + 0,84)^2 \times 0,0375 \times 0,9625}{(0,045 - 0,03)^2} \approx \mathbf{2\,755} \text{ par groupe} \quad (6)$$

Avec une marge de 20%, la taille cible est de **3 300 clients par groupe**, soit **6 600 clients au total**. Sur la base du flux mensuel Olist ($\sim 8\,000$ nouvelles commandes/mois), cet échantillon est atteignable en **environ 2 mois**.

13.3.4 Règle de Décision

- **Intégration CRM complète** si $p < 0,05$ ET lift $\geq 1,2$ ET AUC-lift mesuré (groupe B vs A) $> 1,15$.
- **Révision du seuil de scoring** si $p < 0,05$ mais lift $< 1,2$ (le modèle discrimine mais le seuil 0,40 n'est pas optimal).
- **Abandon** si $p \geq 0,05$ après la durée complète $\rightarrow$ reconsidérer les features du modèle.

13.3.5 Risques et Mesures d'Atténuation

Risque	Impact	Mesure d'atténuation
Flux insuffisant de nouvelles commandes	Test trop long, biais temporel	Vérifier le volume mensuel avant lancement ; prolonger si nécessaire
Interférence avec d'autres campagnes marketing	Biais non contrôlé	Geler toute autre séquence pour les clients dans le test
Dérive du modèle pendant le test	Instabilité des scores	Figurer la version du modèle (snapshot) au lancement du test
Biais de sélection si le scoring affecte l'assignation	Invalide l'expérience	Randomiser <i>avant</i> de calculer le score

TABLE 36 – Risques et mesures d'atténuation — Test A/B n°2

13.4 Plan d'Analyse Statistique Post-Test

Pour chaque test, l'analyse à conduire après la période expérimentale suit le protocole suivant :

1. **Vérification de la randomisation** : comparer les distributions des variables RFM entre groupe A et groupe B via un test du Chi-² ou un test de Mann-Whitney — les deux groupes doivent être comparables au départ.
2. **Test du Chi-² sur les taux de conversion** : variable binaire (a racheté / n'a pas racheté) pour tester l'indépendance entre le groupe et la conversion.
3. **Calcul du lift** : $\text{lift} = p_{\text{groupe B}} / p_{\text{groupe A}}$.
4. **Intervalle de confiance à 95%** sur la différence de proportions :

$$IC_{95\%} = (p_B - p_A) \pm 1,96 \sqrt{\frac{p_A(1 - p_A)}{n_A} + \frac{p_B(1 - p_B)}{n_B}} \quad (7)$$

5. **Analyse de sous-groupes (hétérogénéité de l'effet)** : répliquer l'analyse par état brésilien et par tranche de dépense historique pour détecter si l'effet varie selon le profil client.
6. **Analyse de sensibilité** : vérifier la robustesse des conclusions en excluant les clients ayant été exposés à d'autres campagnes marketing pendant la période.

13.5 Récapitulatif des Deux Tests

Paramètre	Test A/B n°1 (R2)	Test A/B n°2 (R3)
Recommandation testée	Campagne réactivation	Score propension ML
Population	Clients à Risque $\geq$ 300 jours	Nouveaux clients post-1 ^{ère} commande
Taille par groupe	1 400	3 300
Durée	30 jours	60 jours
Métrique primaire	Taux de réachat	Taux de 2 ^{ème} commande
Baseline	2%	3%
MDE	+2 pts (4%)	+1,5 pts (4,5%)
Test statistique	Chi- ² + IC 95%	Chi- ² + IC 95%
Seuil de décision	$p < 0,05$ et lift $\geq$ 1,5	$p < 0,05$ et lift $\geq$ 1,2

TABLE 37 – Récapitulatif comparatif des deux tests A/B

Séquençage recommandé : lancer le **Test A/B n°1** en priorité (délai court, infrastructure simple, impact immédiat), puis démarrer le **Test A/B n°2** en parallèle dès que l'intégration CRM est disponible.

Conclusion Générale

Ce projet a permis de construire un système d'aide à la décision complet et opérationnel, couvrant l'ensemble du cycle data depuis la collecte jusqu'à la visualisation et aux recommandations. Les analyses menées ont confirmé statistiquement que les retards de livraison dégradent la satisfaction client, que les clients fidèles génèrent significativement plus de revenus, et que des disparités géographiques structurelles affectent la qualité logistique. Le dashboard Power BI rend ces résultats accessibles aux équipes non techniques, tandis que le plan A/B Testing fournit un cadre rigoureux pour mesurer l'impact réel des recommandations proposées. L'ensemble constitue une base solide pour guider les décisions stratégiques de la plateforme vers une amélioration durable de la fidélisation et du chiffre d'affaires.